

Bagian B: Implementasi Mini-batch Gradient Descent

Dikumpulkan: Sabtu, 26 Maret 2022 jam 23.59 waktu Edunex.

1. Implementasi backpropagation dengan mini-batch gradient descent sesuai materi kuliah.
 - a. Pada mini-batch gradient descent, update bobot dilakukan per mini-batch. Satu train data dibagi menjadi beberapa mini-batch sesuai parameter **batch_size**.
 - b. Setiap layer dibatasi memiliki neuron dengan fungsi aktivasi yang sama, sedangkan antar layer diperbolehkan memiliki neuron dengan fungsi aktivasi yang berbeda.
 - c. Algoritma yang diimplementasikan adalah backpropagation dengan fungsi **aktivasi** linear, sigmoid, ReLU, dan softmax.
 - d. Untuk linear, sigmoid, dan ReLU, gunakan fungsi loss berupa sum of

$$E = \frac{1}{2} \sum_{k \in \text{outputs}} (t_k - o_k)^2$$

squared errors:

Untuk softmax, gunakan fungsi loss berupa cross entropy:

$$E = -\log(p_k), k=\text{target}$$

- e. Turunan dari fungsi aktivasi:

Linear: $f(x)=x \rightarrow df/dx=1$.

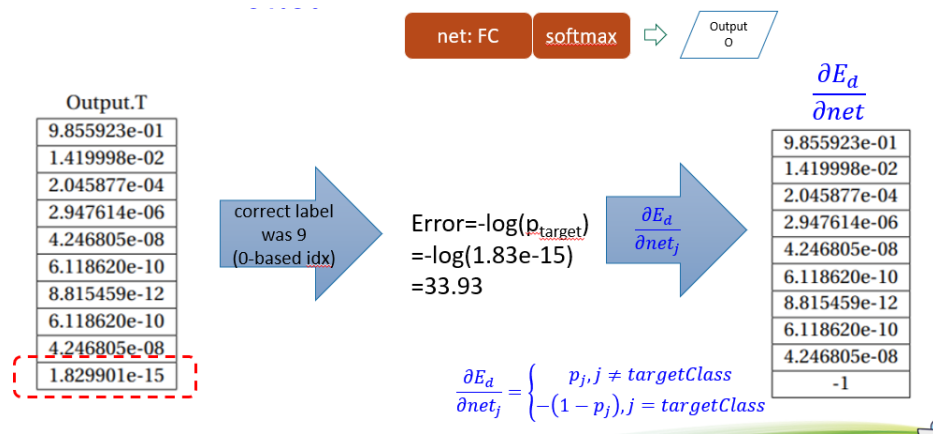
$$\frac{d}{dx} \text{relu}(x) = \begin{cases} 0, & x < 0 \\ 1, & x \geq 0 \end{cases}$$

$$\frac{d}{dx} \text{sigmoid}(x) = \text{sigmoid}(x)(1 - \text{sigmoid}(x))$$

Softmax:

$$\frac{\partial E_d}{\partial \text{net}_j} = \begin{cases} p_j, j \neq \text{targetClass} \\ -(1 - p_j), j = \text{targetClass} \end{cases}$$

Contoh perhitungan turunan softmax:



- f. Dalam mengimplementasikan backpropagation, implementasi berupa perhitungan gradient dengan hasil aturan rantai sebelum mengupdate bobot dengan cara mengalikan gradient*-1***learning rate**. Perhatikan aturan rantai perhitungan gradient utk update bobot ke output layer, berbeda dengan hidden layer. Untuk update bobot output layer w yang menerima input h, gradient dihitung sebagai $dE/dw = dE/d\text{net} * d\text{net}/dw$. Untuk aktivasi output neuron selain softmax, diimplementasikan $dE/dw = dE/d\text{Out} * d\text{Out}/d\text{Net} * d\text{Net}/dw$ sehingga kita mengalikan hasil dari 3 suku yaitu $-(t - \text{out})$, $\text{out}(1 - \text{out})$, dan x . Pada softmax, sudah diberikan langsung $dE/d\text{net}$ sehingga kita mengalikan $dE/dw = dE/d\text{Net} * d\text{Net}/dw$.

Chain rule to compute gradient:

Out: net f ⇒ Output O

$$\frac{\partial E_d}{\partial w_{ji}} = \frac{\partial E_d}{\partial o_j} \frac{\partial o_j}{\partial \text{net}_j} \frac{\partial \text{net}_j}{\partial w_{ji}} = -(t_j - o_j) o_j (1 - o_j) x_{ji}$$

$$\frac{\partial \text{net}_j}{\partial w_{ji}} = x_{ji}; \text{net}_j = \sum_{i \in [0..n_j]} x_{ji} w_{ji}$$

$$\frac{\partial o_j}{\partial \text{net}_j} = \frac{\partial \sigma(\text{net}_j)}{\partial \text{net}_j} = o_j (1 - o_j)$$

$$\frac{\partial E_d}{\partial o_j} = \frac{\partial}{\partial o_j} \frac{1}{2} \sum_{k \in \text{outputs}} (t_k - o_k)^2 = \frac{1}{2} \cdot 2 \cdot (t_j - o_j) \cdot -1 = -(t_j - o_j)$$

- g. Kondisi berhentinya adalah error kumulatif \leq **error threshold** atau **maksimum iterasi** tercapai. Error threshold dan maksimum iterasi merupakan parameter dari mini-batch gradient descent.
- h. Definisikanlah parameter apa saja yang bisa ditangani dalam implementasi kelompok Anda. Parameter yang wajib ada adalah: struktur jaringan (jumlah layer, jumlah neuron setiap layer, fungsi aktivasi setiap layer), learning-rate, error threshold, max_iter, batch_size.
- i. Pengujian kebenaran fungsional dari backprop yang diimplementasikan dilakukan dengan menggunakan kasus uji yang disiapkan oleh asisten (TBD)

- j. Lakukan pembelajaran backpropagation dengan hasil implementasi ini untuk dataset iris untuk semua data (full training), dan menampilkan modelnya.
- 2. Deliverables: a) source code, b) laporan berisi penjelasan implementasi, hasil eksekusi (langkah 2), perbandingan dengan hasil MLP sklearn, dan pembagian tugas setiap anggota kelompok.